Indexation Web

Janvier 2023

Qwant

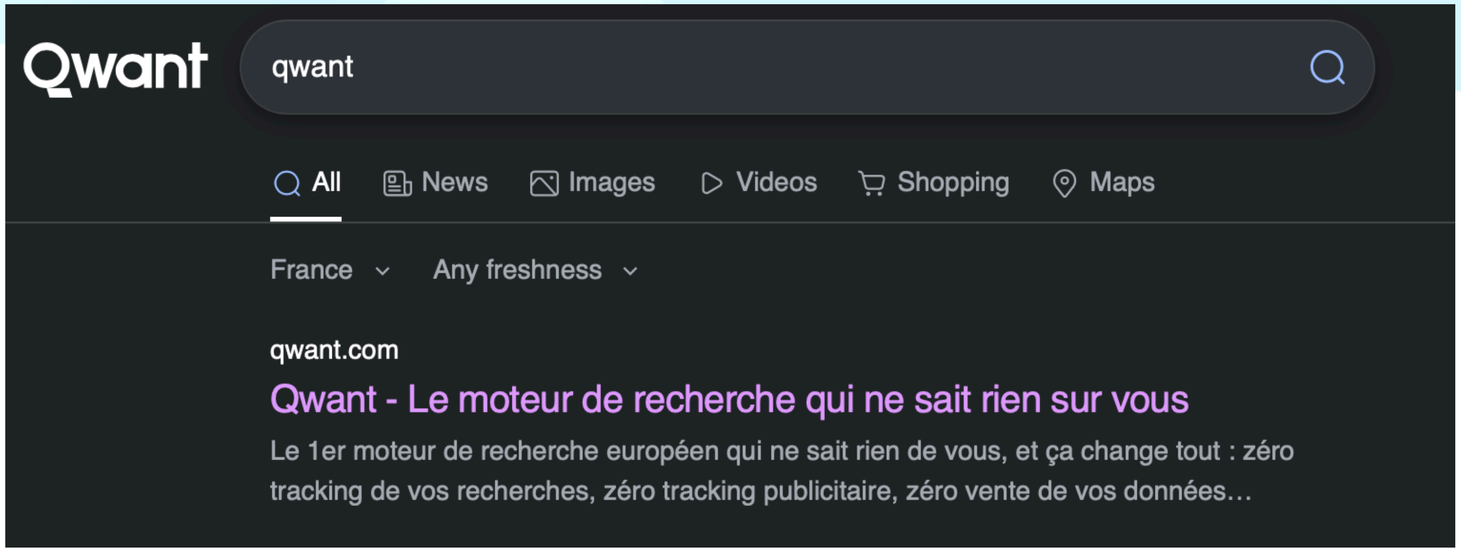

- Lara Perinetti
  l.perinetti@protonmail.com
  Data Scientist NLP | IR

Parlez-moi de vous

- Combien vous êtes dans chaque groupe ?
- Quels langages de programmation vous connaissez ?
- A quel point vous êtes familier avec les notions du web ? (HTML, robots.txt etc.)
- Avez-vous déjà étudié le NLP ? IR ?

Cours Indexation Web

- 6h CM en commun
- 3 * 3h TP
  - Crawl
  - TF-IDF
  - Query Expansion

Cours Indexation Web

Rendus des TPs

- A chaque fin de TP il faudra m'envoyer le code et vous aurez une semaine de plus si vous n'avez pas fini pour me (re) envoyer le code amélioré Vous aurez une semaine de plus pour m'envoyer la version définitive

- TP Crawler - Fonctionnaires 10/01 -> 17/01
  - Ingénieurs 19/01 -> 26/01

- TP Index - Fonctionnaires 20/01 -> 27/01
  - Ingénieurs 23/01 -> 02/02

- TP Query - Fonctionnaires 24/01 -> 03/02
  - Ingénieurs 24/01 -> 09/02

Cours Indexation Web

- Notation
  - Il y aura un mini projet + des features à faire en plus en points bonus
  - Une partie de la note du TP sera sur les commentaires et la simplicité de compréhension et de lancement du code
  - Il faudra toujours m’envoyer votre code avec un fichier main.py et un README.md avec comment lancer le programme + les paramètres par défaut

- Discord du cours: https://discord.gg/nPrvscBV

Table of content

Qu’est-ce qu’un moteur de recherche?

Differents types

- **Web Search**: Google, Qwant, DuckDuckGo, Ecosia etc.
  - Differents formats: HTML, pdf, docx etc.
  - Champs les plus communs: title, content, page rank
- **Shopping Search**: Amazon, Cdiscount, La Redoute etc.
  - Leurs propres structures de données, appliquer des filtres
  - Champs les plus communs: nom du produit, prix, image
- **Desktop search**: sur les ordinateurs personnels
  - fichiers, emails, pages webs dans l’historiques des recherches
  - Séparer les sources de données

Qu’est-ce qu’un moteur de recherche?

SERP Search Engine Results Pages

Paid Results

Organic Results

Search Engine Features

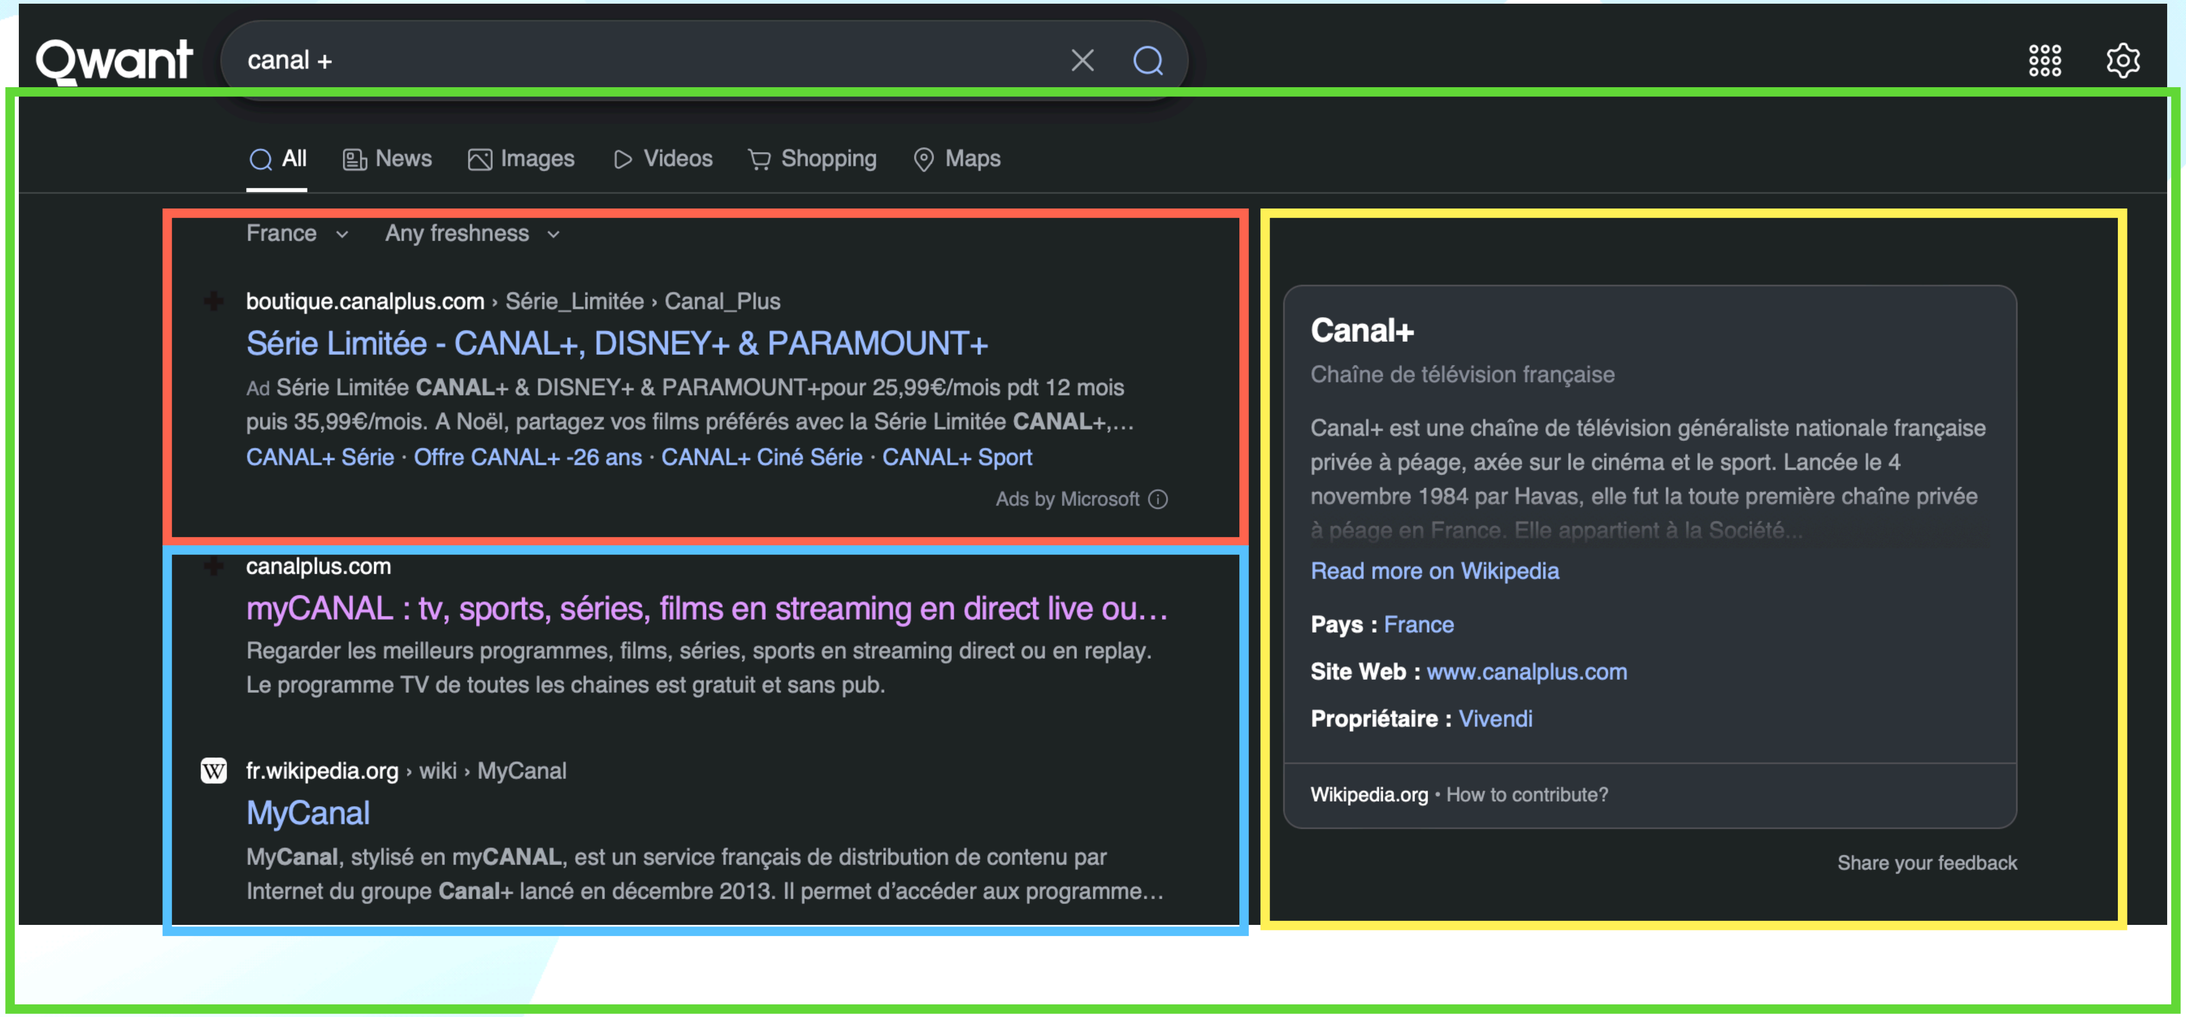

Information Retrieval

- *"Information retrieval is a field concerned with the structure, analysis, organization, storage, searching, and retrieval of information."* (Salton, 1968)
- La recherche d'information consiste à trouver des documents non structurés qui répondent à un besoin d'information dans une grande collection de documents.
- Recommandation systems (Netflix, Spotify) —> ne seront pas traités dans ce cours
- Deux problématiques majeures
  - De nombreux facteurs influencent la décision d'une personne concernant ce qui est pertinent —> évaluation subjective
  - Les requêtes par mot-clé sont souvent de mauvaises descriptions des besoins réels

Information Retrieval

Qu’est-ce qu’un document web?

- On va se concentrer sur les pages HTML
  Balises les plus communes:

```
<head>
    <title></title>
    <link></link>
</head>
<body>
    <p></p>
    <div></div>
    <h1></h1>
</body>
```

Exemple

- La structure et le nom des balises sont reglementés
- Peuvent contenir du texte, des films, des images, ou tout à la fois
- Dans le web, les pages peuvent avoir plusieurs sujets/topics que l’on va essayer d’extraire
- Sont augmentées de métadonnées
  -> Les métadonnées sont des informations sur un document qui ne font pas partie du contenu du texte, comme le type de document

Information Retrieval

Qu’est-ce qu’une requête web ?

- Spécificités d’une requête web: souvent courte (un ou deux termes) et ambiguë
- On définit 3 intentions principales pour une requête web
  - Navigationelle
  - Transactionnelle
  - Informationnelle
- On peut définir plusieurs topics pour une requête web
  - Exemple:
    requête: Jaguar
    topics: animal / voiture

Information Retrieval

What is a web query ?

Exemples de requetes d’utilisateurs Qwant en décembre 2022

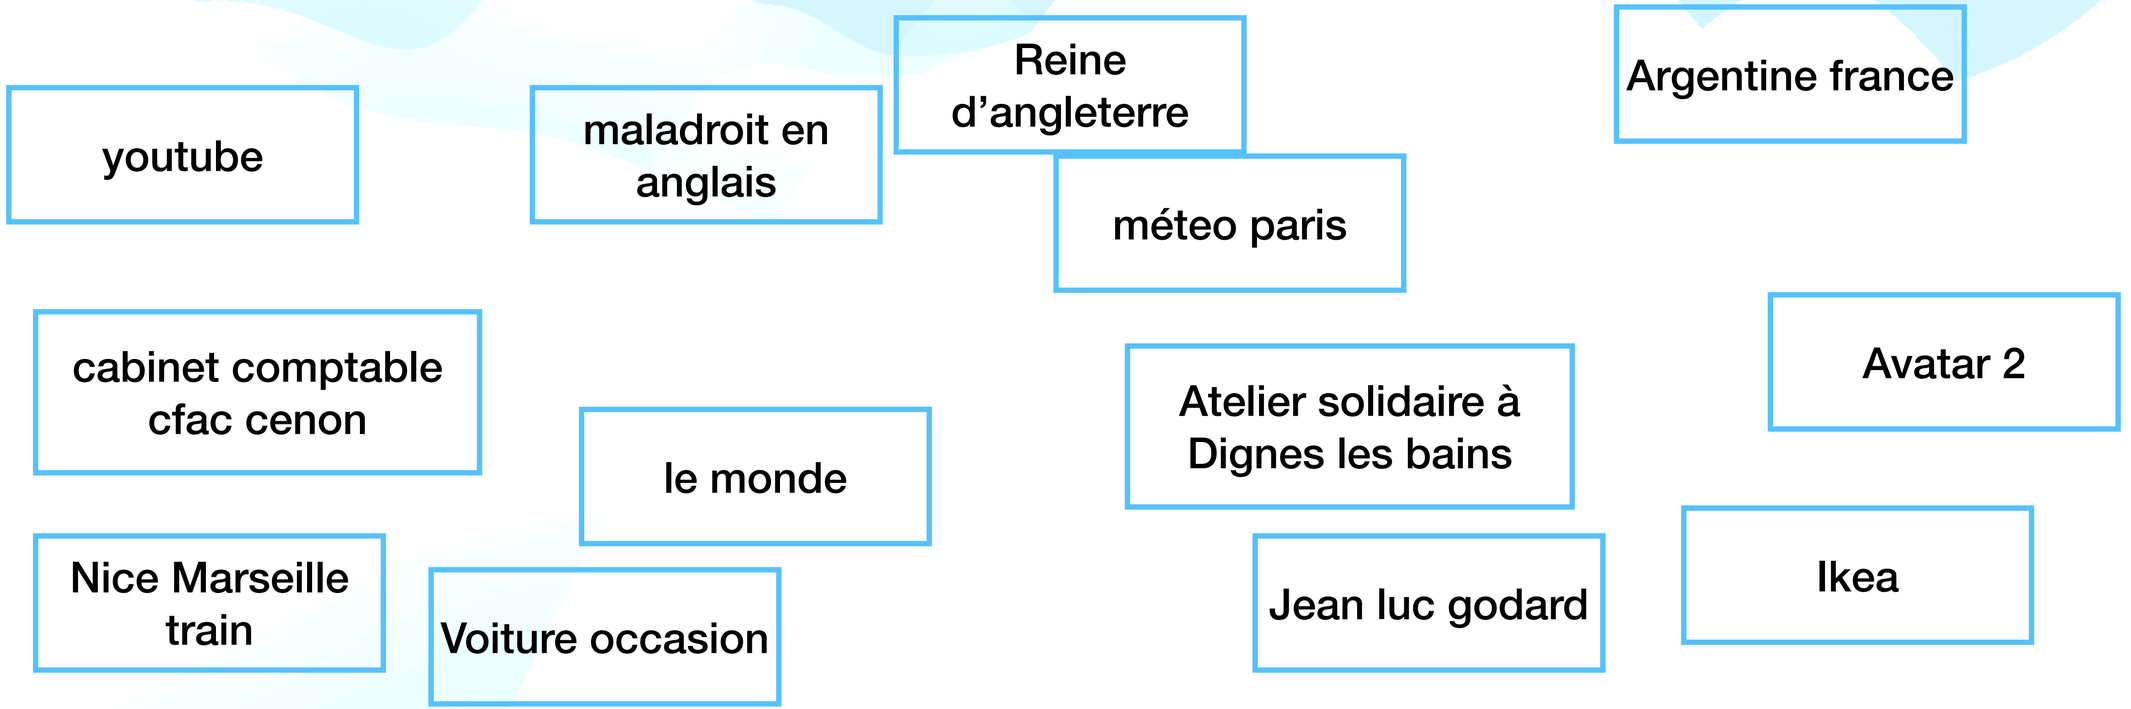

Les classer par intention (informationnelle, transactionnelle, navigationnelle)

Information Retrieval

What is a web query ?

Requetes d’utilisateurs Qwant en décembre 2022

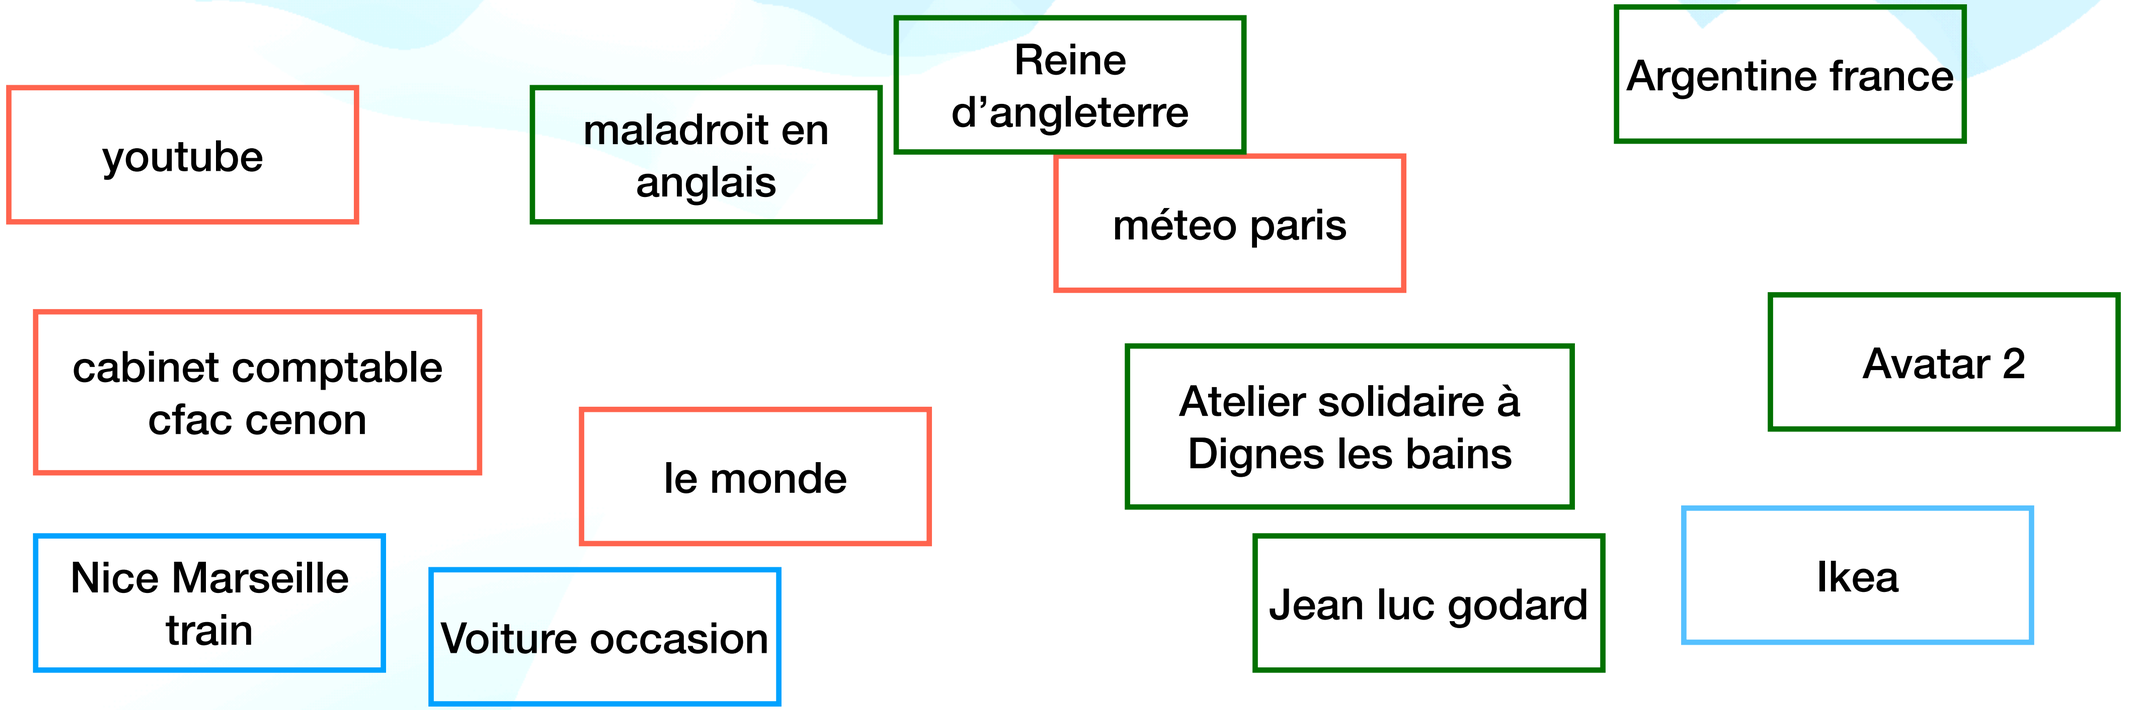

Les classer par intention (informationnelle, transactionnelle, navigationnelle)

Information Retrieval

What is a web query ?

Requêtes d’utilisateurs Qwant en décembre 2022

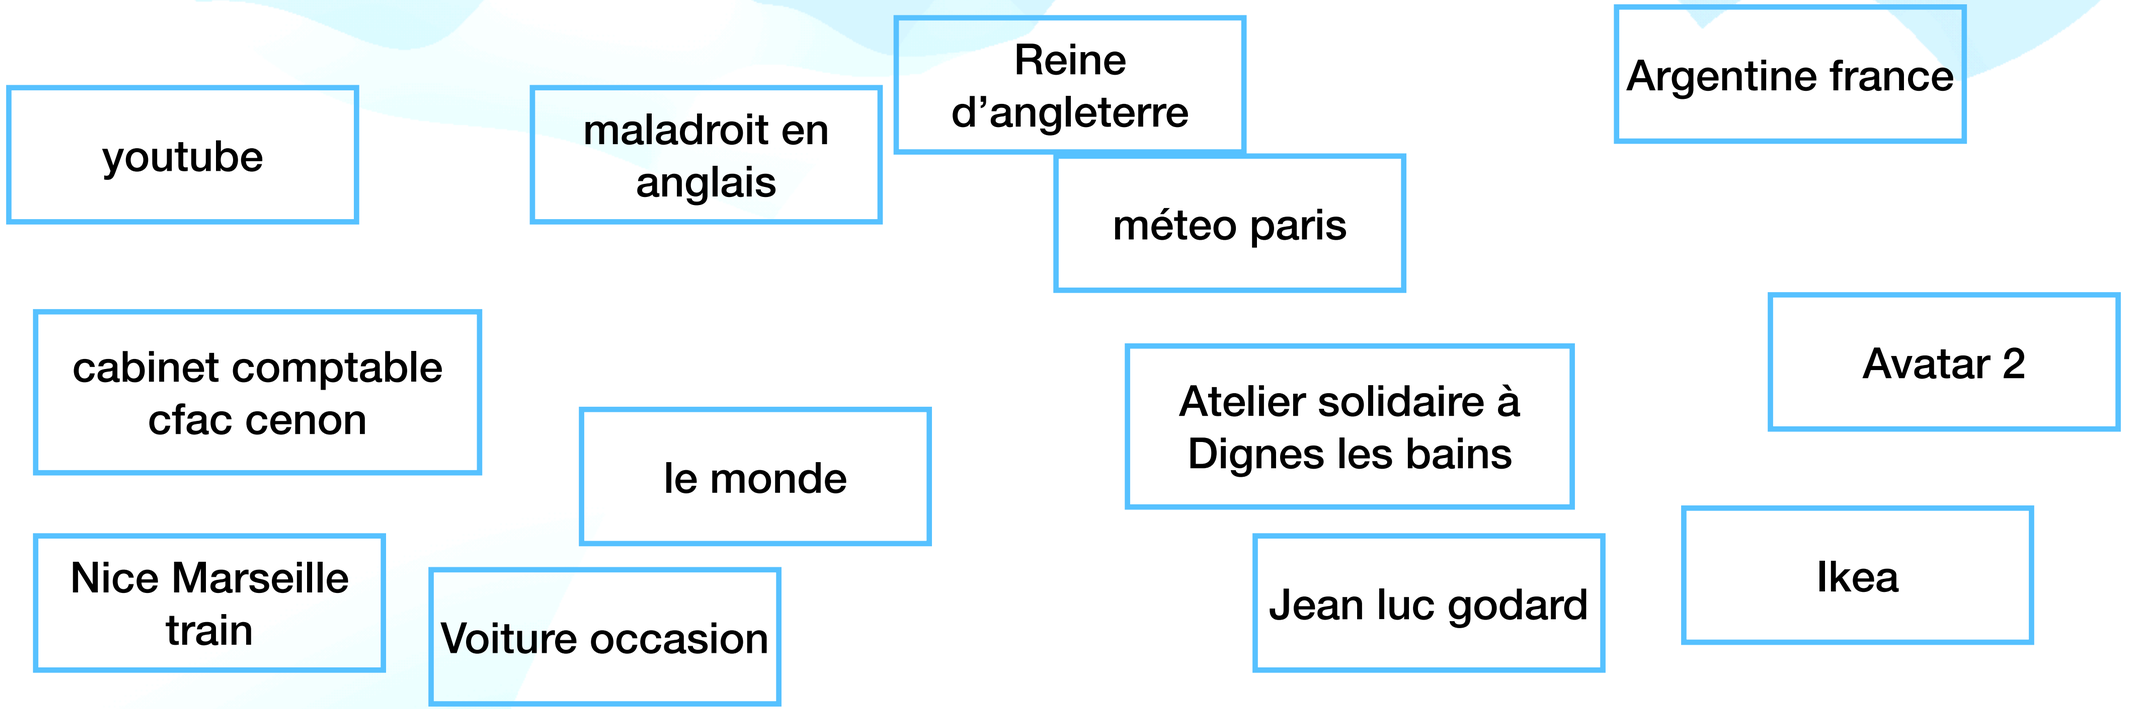

Les classer par topics (pas plus de deux topics par requête)

Information Retrieval

What is a web query ?

Requêtes d’utilisateurs Qwant en décembre 2022

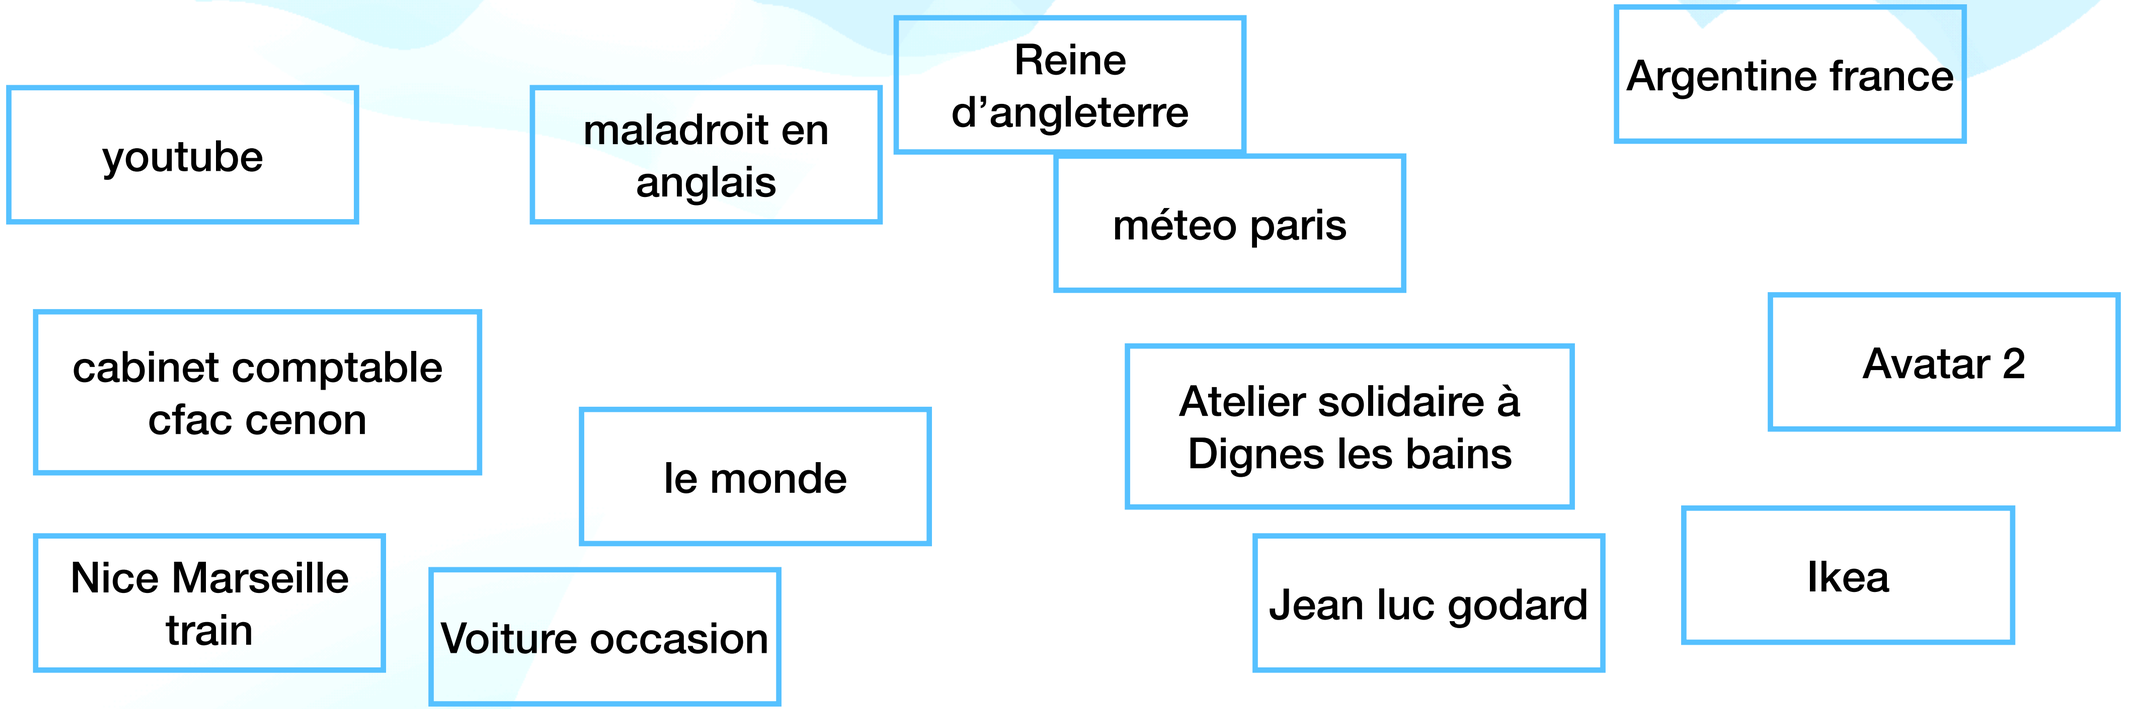

shopping, news, entertainment, sports, etc.

Partie 1
Constitution d’un index web

Architecture d’un moteur de recherche

Architecture d’un moteur de recherche

Objectifs

- Qualité : Nous voulons être en mesure de récupérer l'ensemble de documents les plus pertinents possibles pour une requête donnée.
- Rapidité : Nous voulons traiter les requêtes des utilisateurs aussi rapidement que possible.

Architecture d’un moteur de recherche

Des pages webs à l’index

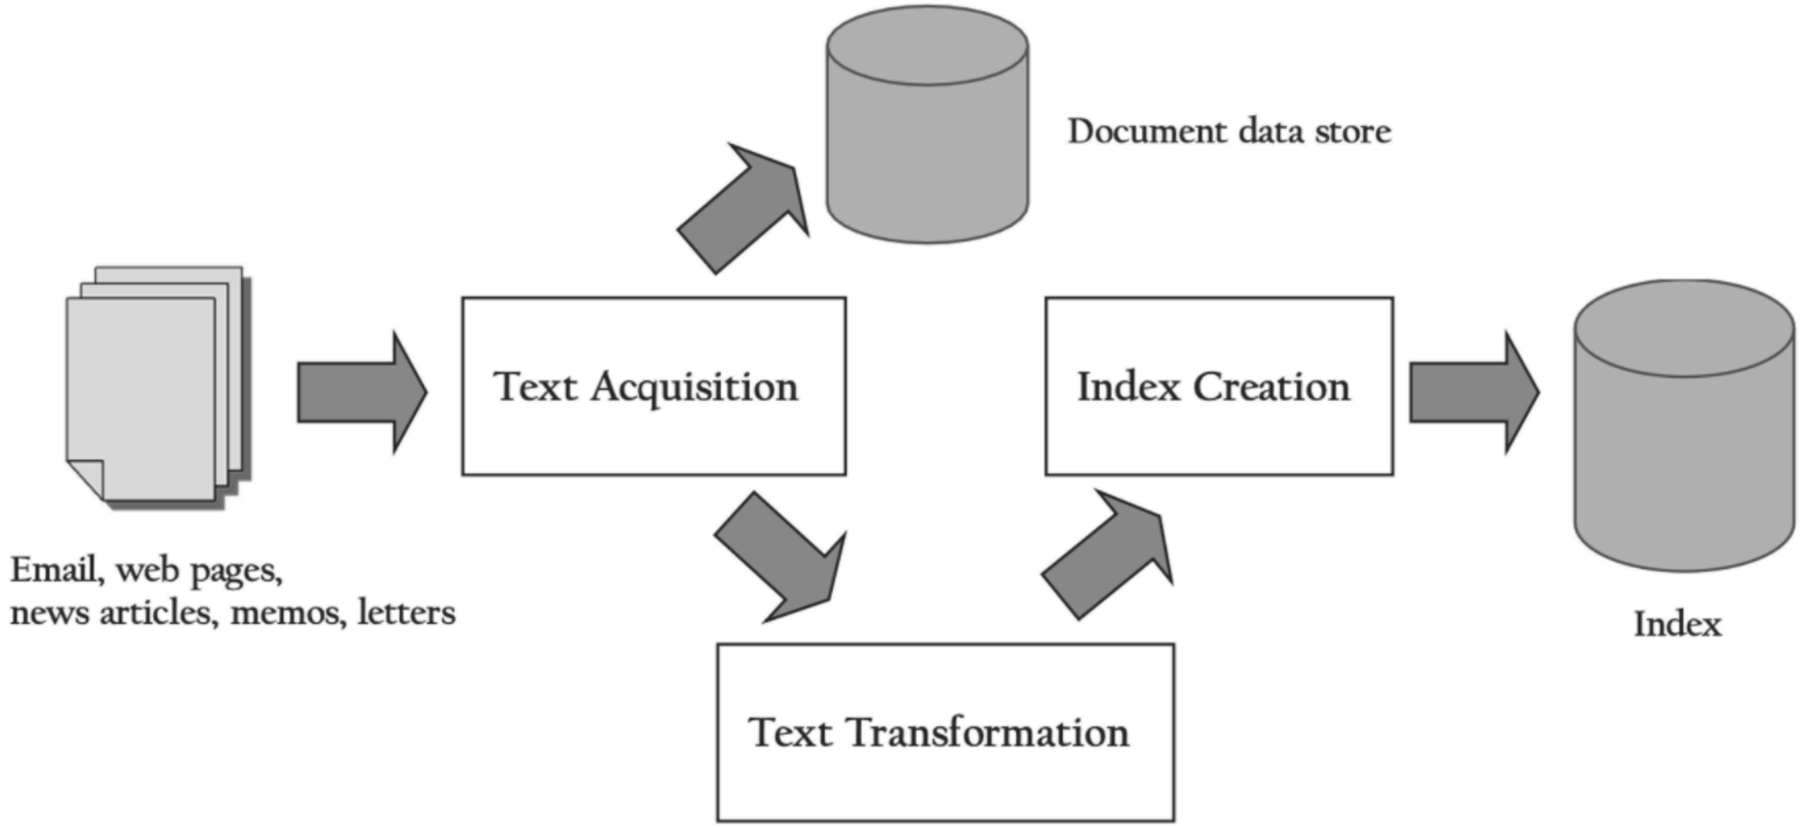

Fig. 2.1. The indexing process

Des pages webs à l’index
Text Acquisition

- identifie et rend disponible les documents que l’on voudra chercher

1. Quels documents ?
    - partir d’une collection de documents clés en main
    - chercher ces documents via une tache de **crawl**
2. Où les stocker?
   Une **base de données relationnelle** peut être utilisée pour stocker les documents et leurs métadonnées.
3. La notion de crawler
    - Un crawler est conçu pour suivre les liens sur les pages web pour découvrir et télécharger de nouvelles pages
    - Un bon crawler doit être capable
      de gérer efficacement l'énorme volume de nouvelles pages sur le Web,
      tout en veillant à ce que les pages qui ont pu être modifiées depuis la dernière visite d'un crawler restent "fraîches" pour le moteur de recherche

Des pages webs à l’index

Text Transformation

- Parsing —> hierarchy extraction
- Stopping —> removing stop words
- Stemming / Lemmatization
- Link extraction / analysis
- Information extraction (language, topic etc.)

Des pages webs à l’index

Index creation

- Prend la sortie de la transformation de texte pour créer les index qui contiendront les informations sur les documents
- Compte tenu du grand nombre de documents, la création d'un index doit être efficace, tant en termes de temps que d'espace.

Architecture d’un moteur de recherche

De la requête aux résultats finaux

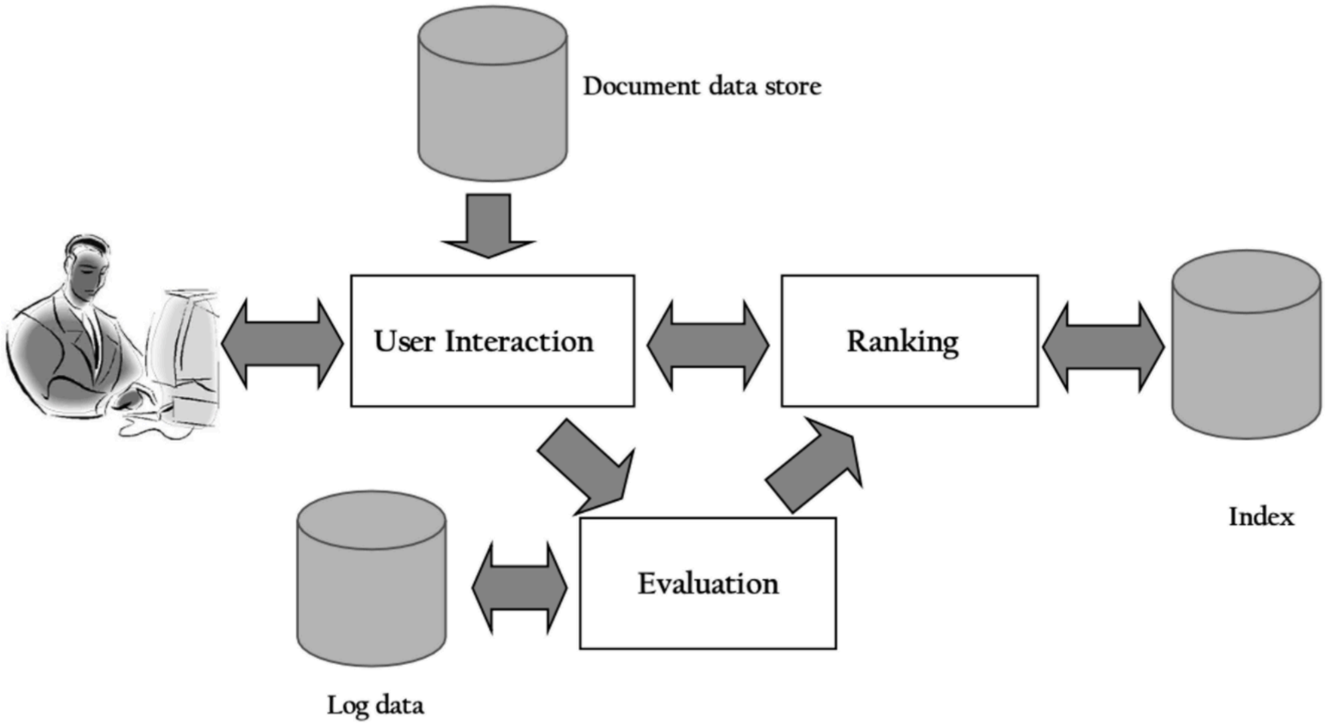

Fig. 2.2. The query process

De la requête aux résultats finaux

User interaction

- Reçoit en input la requête de l’utilisateur et la transformer pour qu’elle soit comprise par l’index
- La requête de l’utilisateur peut comprendre le texte meme de la requête mais aussi toutes les métadonnées associées (langue de l’utilisateur, topics de la requête, heure, jour de la semaine etc.)
- Inclut la transformation de la requête
  - Spell checking
  - Augmentation de la requête
  -

De la requête aux résultats finaux

Ranking

- Reçoit en input les documents qui ont survécu au filtre de la requête et leur donne un score en fonction de la requête.
- L’ordonnancement doit être à la fois efficace, puisque de nombreuses requêtes doivent être traitées en peu de temps, et effectif, puisque la qualité du classement détermine si le moteur de recherche atteint l'objectif de trouver des informations pertinentes.

De la requête aux résultats finaux

Evaluation

- Evaluation “offline”
- Evaluation “online”

Partie 1
Constitution d’un index web

Crawler le web

Crawler le web

Décider de ce qu'il faut rechercher

- Le Web est immense et en constante expansion
- Les pages Web changent constamment
  Même les documents utiles peuvent devenir moins utiles avec le temps.
- On ne peut pas se permettre de stocker toutes les pages du web
- On évalue un crawler par la **couverture (coverage)** qui mesure la quantité de documents pertinents que l'on réussit à récupérer
  Et par la **fraicheur (freshness)** des pages stockées.
- Un crawler se doit d'être poli, il se doit d'espacer les crawl pour une url donnée

Crawler le web

Qu’est-ce qu’une page web ?

- Scheme
  http | https | ftp | smtp
- Subdomain
  indique le type de resource
  www | blog | audio etc.
- Domain
  indique l’organisation
- TLD
  indique le type d'organisation à laquelle le site web est enregistré.
  pays: fr | co.uk | de
  region: re
  autre: com | org | net

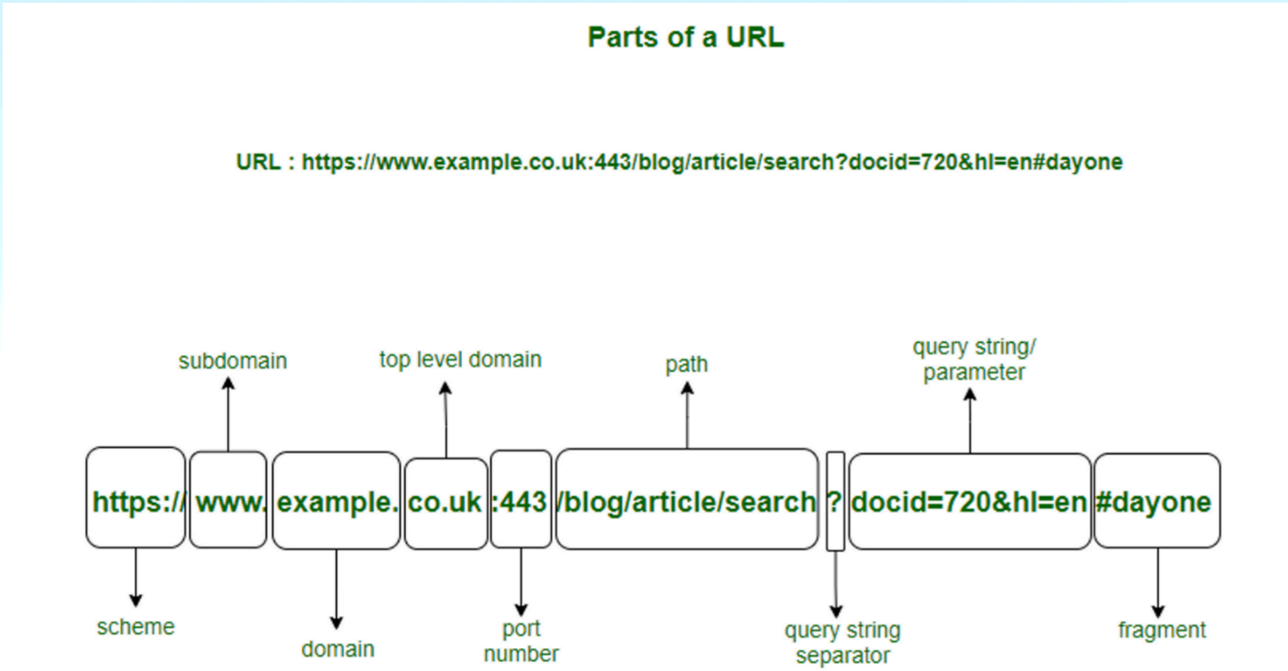

Crawler le web

Qu’est-ce qu’une page web ?

- Path
  indique la localisation de la page dans son domaine
- Query
  les paramètres d'un site web.
- Fragment
  pour arriver directement à une certaine balise dans le document html

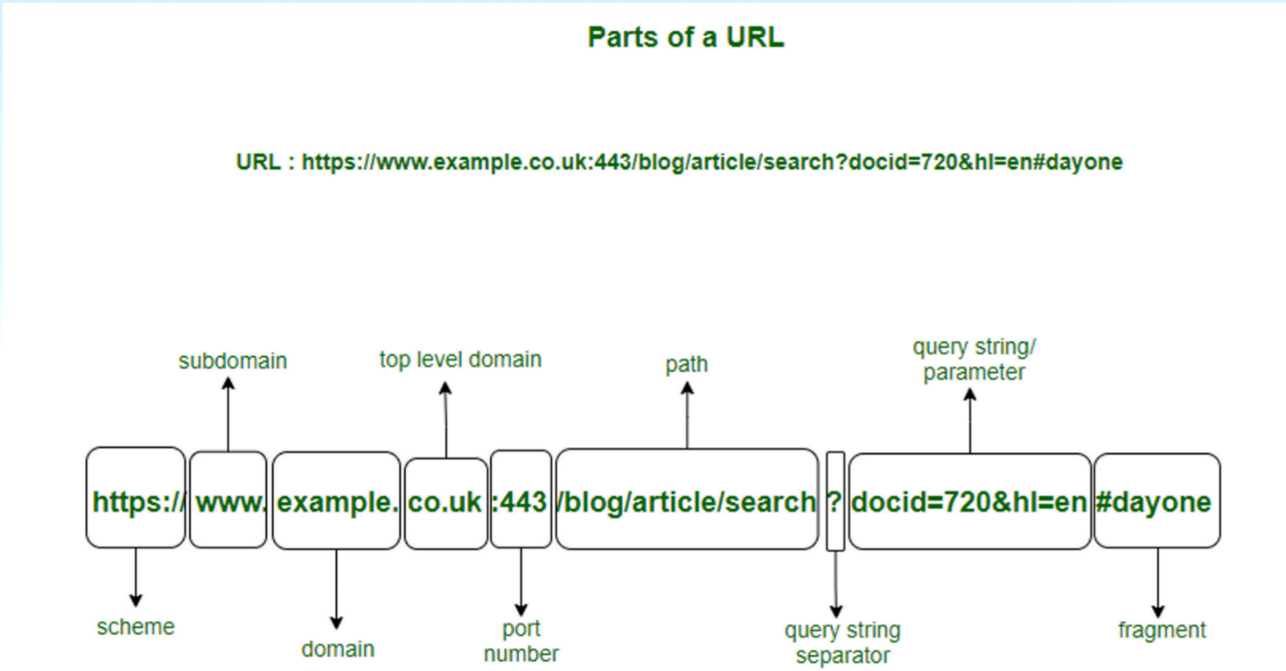

Crawler le web

Algorithme

- Input: un ensemble d’urls
- Les urls sont ajoutées à une **file d’attente (ou frontier)** de requêtes URL
- Le crawler commence à récupérer les pages de la file d'attente des requêtes
- Les pages téléchargées sont analysées pour trouver des balises de liens qui pourraient contenir d'autres URL utiles à récupérer.
- Si le crawler trouve une nouvelle URL qu'il n'a pas vue auparavant, elle est ajoutée à la frontier.
- Le robot continue jusqu'à ce qu'il n'y ait plus de nouvelles URL à ajouter à la file d’attente ou que le disque soit plein.

- La frontier peut être une file d'attente standard ou être ordonnée de manière à ce que les pages importantes soient placées en tête de liste.

Crawler le web

Controler le crawler: robots.txt

- Les propriétaires de sites Web utilisent le fichier /robots.txt pour donner des instructions sur leur site aux crawlers
- Exemples de robots.txt
  - Site important
  - Site de niche
- Guidelines de google
- Informations sur le crawler de Qwant

Crawler le web

La notion de fraicheur

- Il n'est pas possible de vérifier constamment la fraicheur de toutes les pages
- On choisit donc de vérifier les pages importantes et celles qui changent fréquemment
- La fraîcheur est la proportion des pages explorées qui sont actuellement fraîches.
  Pb: si une page se met à jour toutes les 2 secondes

Crawler le web

La notion de fraicheur

- Il n'est pas possible de vérifier constamment la fraicheur de toutes les pages
- On choisit donc de vérifier les pages importantes et celles qui changent fréquemment
- La **fraîcheur** est la proportion des pages explorées qui sont actuellement fraîches.
  Pb: si une page se met à jour toutes les 2 secondes
  - La meilleure stratégie est alors d’arrêter de la crawler
- C’est pour cela que l’on va plutôt vouloir calculer l’âge d’une page

Crawler le web

La notion de fraicheur

- Une page est **fraîche** si elle représente la copie la plus récente d'une page Web, et périmée dans le cas contraire.
  La fraîcheur est la fraction des pages crawlées qui sont actuellement fraîches.

- Les pages deviennent tout de suite fraiches quand elles sont crawlées, mais dès que la page change, la page explorée devient périmée.

- La page a un **âge** de 0 jusqu'à ce qu'elle soit modifiée, puis son âge augmente jusqu'à ce que la page soit à nouveau explorée.

- Optimiser l’âge ne nous fera jamais dire qu’il vaut mieux arrêter de crawler une page

Crawler le web

Sitemaps

- Certains sites web exposent une sitemap aux crawler dans le robots.txt
- Exemple
- Quel est l’interet de créer cette sitemap pour l’administrateur du site?

Crawler le web

Sitemaps

- Certains sites web exposent une **sitemap** aux crawler dans le robots.txt
- Exemple
- Quel est l’interet de créer cette sitemap pour l’administrateur du site?
  - Il indique aux moteurs de recherche des pages qu'ils ne trouveraient pas autrement.
  - Cela permet de réduire le nombre de requêtes que le crawler envoie à un site web sans sacrifier la fraîcheur des pages.

Crawler le web

Stocker les documents

- La recherche de documents est couteuse en termes de CPU et de réseau.
- On va vouloir conserver une copie des documents déjà crawlés au lieu d'essayer de les récupérer à chaque fois qu’on lance un tour de crawl.
- En général on utilise une BDD relationnelle avec pour identifiant unique du document un hash de l’URL
- Exemple de BDD: Big Table

Crawler le web

Détecter les documents dupliqués

- Tache plutôt simple
- On va souvent utiliser des techniques qui calculent les bytes des documents
- Baseline: **checksum technique**:
  T r o p i c a l f i s h
  54 72 6F 70 69 63 61 6C 20 66 69 73 68 result = 508
- **cyclic redundancy check**, une autre technique qui prend en compte la position des bytes.
- Attention: **http://monsite.com** != **https://monsite.com**

Crawler le web

Détecter les documents “presque” dupliqués (ou near duplicates)

- Tache plus complexe
- Pour une url donnée, on va chercher à trouver tous ses “presque” duplicats dans la BDD.
- Pour cela, il faut représenter les documents
  - Soit en le hashant (e.g: sim-hash)
  - Soit avec des embeddings (vecteur dense de représentation d’un document)

Crawler le web

Le deep web

- Le deep web représente toutes les pages web qui sont compliquées à trouver pour un crawler et qui sont bien souvent non indexées par les moteurs de recherche
- Ces urls sont bien plus nombreuses que les pages web conventionnelles
  Et elles sont légales
- Contrairement aux pages du dark web

Partie 1
Constitution d’un index web

Document Processing

Document Processing

Extraire des informations des documents

- Avant d’ajouter nos documents dans un index, on va vouloir en extraire le plus d’informations possibles qui nous aideront à répondre de la manière la plus pertinente
  - Text Processing
  - Structure du document
  - Analyse des liens
  - Document embeddings

Text processing

Document Processing

Text Processing | Vocabulaire

- Quelques mots apparaissent très souvent, beaucoup de mots n'apparaissent presque jamais.
- La taille du vocabulaire augmente avec le corpus
  Mais il y a de moins en moins de mots nouveaux lorsque le corpus est déjà important
- Le vocabulaire est constitué de
  - mots bien orthographiés (dans différentes langues)
  - mots avec fautes d’orthographe
  - mots inventés (e.g: noms de produits, de sociétés, etc.)
  - adresses mails, suites de chiffres
  - etc.

Document Processing

Text Processing | Des mots aux tokens

- On ne va plus parler de mots mais de token
- On va subdiviser le texte en plusieurs tokens
- Une tokenization par langue:
  - En anglais ou en français, plutôt simple:
    “The apple is red” —> [“the”, “apple”, “is”, “red”]
  - Les langues CJK ont une tokenization adapté aux signes.
- Il doit y avoir la meme tokenization du côté du document que du côté de la requête
- Une étape clé dans le text processing, si la tokenization est mal faite, les étapes d’après vont en pâtir. Elle est tellement important qu’aujourd’hui on utilise souvent un modèle entrainé pour tokenizer.
- On parle aussi de tokenization pour diviser les documents en phrases, en characters, en morphemes ou “word-pieces”

Document Processing

Text Processing | Stemming et lemmatisation

- En fonction des langues, on peut avoir besoin de faire référence à une représentation simplifiée des tokens, pour des questions de match avec la requête ou de taille du vocabulaire

- Documents: “nous allons à la boulangerie”

Token original	Token stemmé	Token Lemmatisé
allons	all	aller

- En fonction des langues peut etre plus ou moins intéressant:
  - Les langues CKJ n’ont pas de variation morphologique
  - Les langues slaves ont parfois plus de 7 déclinaisons possibles pour un meme nom commun

Structure du document

Document Processing

Document Structure | Supprimer le bruit contenu dans les documents

- Tache: Boilerplate removal
- De nombreuses pages web contiennent du texte, des liens et des images qui ne sont pas directement liés au contenu principal de la page.
- Ces éléments supplémentaires sont pour la plupart du bruit et peuvent avoir un impact négatif sur le classement de la page.

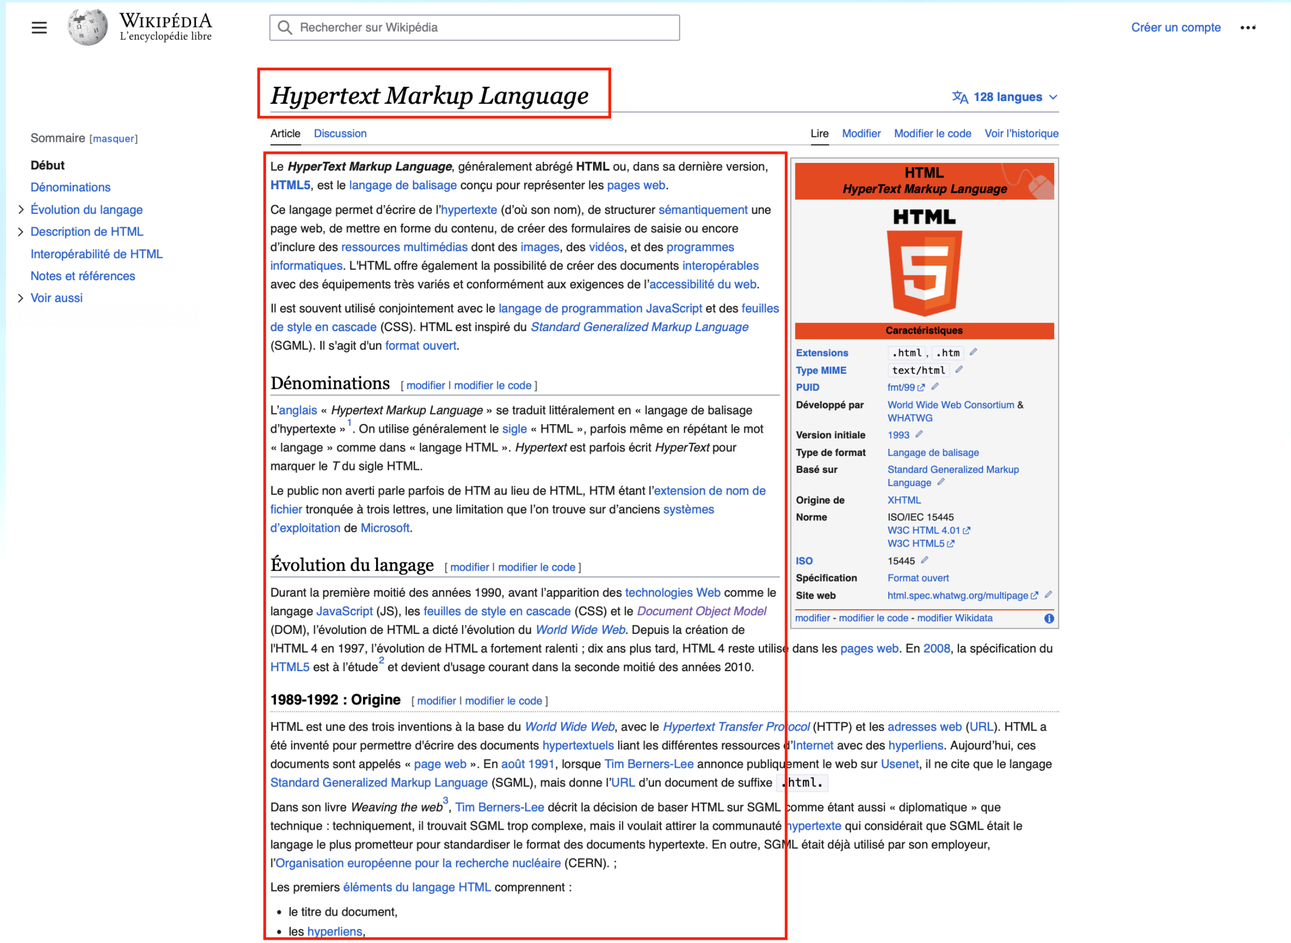

Document Processing

Document Structure | Extraire d’autres informations que le contenu principal

- Interet de l’HTML: le nom des balises est codifié.
- Il y a certaines balises qui nous aident à extraire des informations:
  - <meta> pour les métadonnées
  - <img> pour les images
  - <title> pour les titres
  - <a> pour les ancres

Analyse des liens

Document Processing

Analyse des liens

- Le crawler s’aide des liens entre les pages pour trouver de nouvelles pages à crawler
- Ces liens nous permettent
  - de créer un graphe du web
  - de comprendre les relations entre les pages
  - d’ordonner les pages en fonction de leur importance
- Exemple

Document Processing

Analyse des liens | Le texte des ancres

- En général, un texte court qui décrit la page vers laquelle on va cliquer
  Il peut avoir les memes caractéristiques qu'une requête web

- Extraire le texte des ancres nous permet ensuite de matcher ce texte avec la requête

- Peut etre très utile pour les abréviations:
  YouTube.com -> yt, ytb

- Mais doit etre nettoyé:
  "Cliquez ici", "check here", "découvrir"

Document Processing

Analyse des liens | La popularité d’une page

- La majeure partie du web est composée de pages assez peu interessantes, datées, ou de pages que l’on qualifie de spam
- On va donner un ou plusieurs score de qualité, de confiance aux urls
- Le plus connu: Page Rank

Document Processing

Analyse des liens | Page rank

- Algorithme qui calcule un score de popularité pour une url donnée
- Idée:
  - Plus il y a d'urls qui pointent vers une url A, plus A est populaire
  - Tous les liens ne comptent pas de la meme manière:
    Si toutes les urls qui pointent vers A ne sont pas populaires, la popularité de A sera faible —> si on prend en compte la popularité des pages qui pointent vers A, on ne donnera pas un gros score aux spams
- Keywords:
  - Page = document = site internet = url
  - Inlinks: liens pointant vers une page web
  - Outlinks: liens d'une page vers les autres pages

Document Processing

Analyse des liens | Page rank

- Algorithme “Random surfer model”

```
func random_surfer_model(threshold)
        r  <- random(0,1)

         if r < threshold
            choisis une page web random
         else
            click sur un lien dans la page web courante

         random_surfer_model(threshold)
```

  - En général, la variable threshold est plutôt petite, par exemple 0.15, pour que l’algorithme ait plus de chances de cliquer sur un lien que de choisir une autre page web

- Le score de page rank d’une page est la probabilité que le surfer arrive sur cette page

Document Processing

Analyse des liens | Page rank

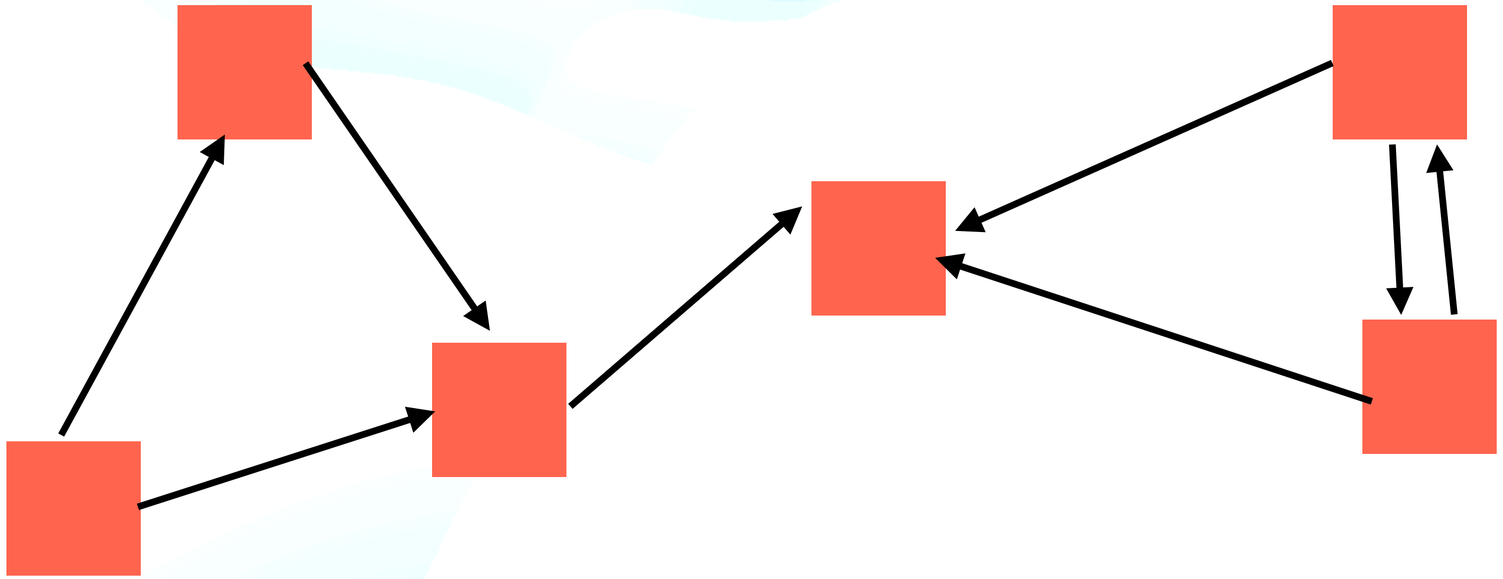

Document Processing

Analyse des liens | Page rank

- L’algorithme tourne “à l’infini” et va donc visiter tous les sites webs plusieurs fois. Mais il est plus probable qu’il visitera un site populaire des milliers de fois plus souvent qu'un site impopulaire.
- Si on ne lui permettait pas de chercher une nouvelle page random (premier if) il resterait bloqué
  - sur des pages qui n'ont pas de liens,
  - des pages dont les liens ne pointent plus vers aucune page,
  - ou des pages qui forment une boucle.

Document Processing

Analyse des liens | Page rank

- Au départ toutes les pages ont le meme page rank

Document Processing

Analyse des liens | Page rank

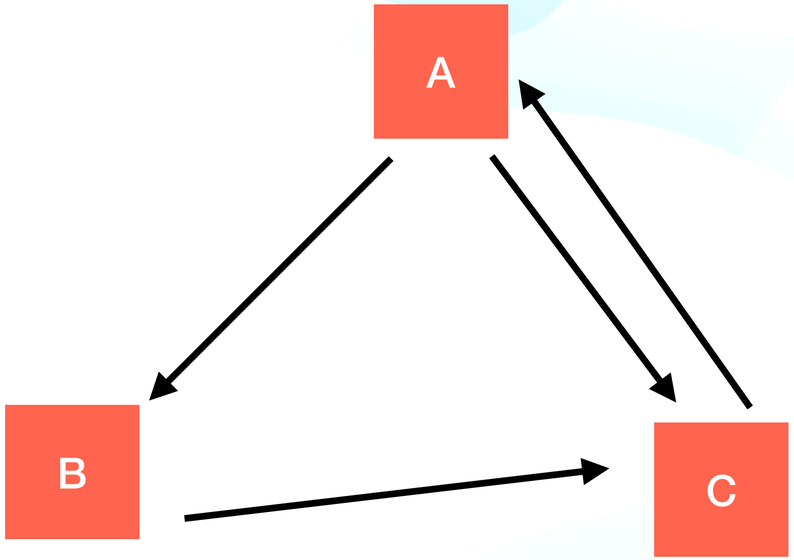

- Le page rank d'une page dépend de celui des autres pages
- Plus une page a de liens, moins ses liens ont un poids dans le calcule du page rank
- **Si on ne prend en compte que les inlinks**
  Temps 1:
  PR(C) = PR(A) / 2 + PR(B) / 1 = 0.33 / 2 + 0.33 = 0.5
  PR(A) = PR(C) / 1 = 0.33
  PR(B) = PR(A) / 2 = 0.17

  Temps 2:
  PR(C) = 0.33/2 + 0.17 = 0.33
  PR(A) = 0.5
  PR(B) = 0.25

.

Document Processing

Analyse des liens | Page rank

$$PR(u) = \frac{\lambda}{N} + (1 - \lambda) \cdot \sum_{v \in B_u} \frac{PR(v)}{L_v}$$

- **Si on ne prend en compte que les inlinks ET le random sur les pages**

- N -> le nombre de documents
- Lambda -> probabilité de choisir une page random
  1-lambda -> probabilité de cliquer sur un lien
- Bu -> inlinks de l'url u
- Lv -> # outlinks depuis l'url v

Document Embeddings

Document Embeddings

Dense representations | BERT-like embeddings

- Embeddings: représentation vectorielle d'une string (plus ou moins longue)
- BERT-like embeddings: représentation contextualisée au niveau du word-piece
  Exemple:
  - Danone est mon yaourt préféré
  - Je déteste Danone
  Le vecteur de Danone sera différente
- Problèmes en recherche d'information:
  - Ce sont des representation assez longues à générer
    Comme elles dependent du contexte, on ne peut pas simplement avoir une hashmap de token -> vecteur
  - Ces embeddings ont une contrainte de taille de la string en input (en général max 512 word pieces), un document web est souvent bien plus long
    On choisit alors
    - soit de représenter le début du document
    - soit de diviser le document en chunks de max 512 wp et de multiplier les vecteurs résultants
    - Soit de partir d'un summary du document

Document Embeddings

Dense representations | ColBERT

- Similarité entre la requête et le document
- Un meme modele qui encode la requête et le document séparément et donne un score de similarité entre un document et une requête
- On va encoder le document au moment de l’indexation
  On n’aura plus qu’à encoder la requête

Partie 2
Traitement de la requête et ordonnancement des résultats

Index